

OR

S.Olivia

September 2023

目录

Chapter 1

Introduction

1.1 数学基础

1.1.1 梯度与黑塞矩阵

简便记法

1.1.1.1 梯度

$$\nabla f(x_1, x_2, x_3) = \left(\frac{\partial f}{\partial x_1}, \frac{\partial f}{\partial x_2}, \frac{\partial f}{\partial x_3} \right)^T \quad (1.1)$$

1.1.1.2 黑塞矩阵

$$\nabla^2 f(x_1, x_2, x_3) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_3 \partial x_1} \\ \frac{\partial^2 f}{\partial x_1 \partial x_2} & \frac{\partial^2 f}{\partial x_2^2} & \frac{\partial^2 f}{\partial x_3 \partial x_2} \\ \frac{\partial^2 f}{\partial x_1 \partial x_3} & \frac{\partial^2 f}{\partial x_2 \partial x_3} & \frac{\partial^2 f}{\partial x_3^2} \end{pmatrix} \quad (1.2)$$

简而言之，式 (1.2) 即为式 (1.1) 逐行关于参数（即 x_1, x_2, x_3, \dots ）求偏导。

1.1.2 正定矩阵

对一个 n 阶方阵 M ，如果其对任意非零向量 Z 都有 $Z^T M Z > 0$ ，其中 Z^T 为 Z 的转置，则 M 为正定矩阵。

定理：对于 n 阶实对称矩阵 M ，下列条件是等价的：

1. M 是正定矩阵。
2. M 的特征值均为正。
3. M 的一切顺序主子式均为正。

1.2 基本理论

1.2.1 数学规划模型的一般形式

$$(fS) = \begin{cases} \min & f(x) \\ \text{s.t.} & x \in S \end{cases} \quad (1.3)$$

1.2.2 凸集、凸函数和凸规划

1.2.2.1 凸集

定义：设 $S \subset \mathbf{R}^n$ ，如果 $\mathbf{x}^{(1)}, \mathbf{x}^{(2)} \in S, \lambda \in [0, 1]$ ，均有

$$\lambda \mathbf{x}^{(1)} + (1 - \lambda) \mathbf{x}^{(2)} \in S \quad (1.4)$$

则称 S 为凸集

集中任意两点连成的线段必属于该集合；规定空集 \emptyset 为凸集，单点集 $\{x\}$ 为凸集。

性质：

1. 凸集的交集是凸集
2. 凸集的内点集是凸集
3. 凸集的闭包是凸集
4. 分离和支撑：凸集边界上任意点存在支撑超平面；两个相互不交的凸集之间存在分离超平面

有一特殊的凸集：凸锥

定义：设非空集合 $C \subset \mathbf{R}^n$ ，如果 $\forall \mathbf{x} \in C$ 对 $\forall \lambda > 0$ 有 $\lambda \mathbf{x} \in C$ ，则称 C 为以 0 为顶点的锥（不一定含 0 点）。若 C 又是凸集，则称 C 为凸锥。

1.2.2.2 凸函数

定义 2-7：设 $S \subset \mathbf{R}^n$ ，非空，凸集，函数 $f: S \rightarrow \mathbf{R}$ ，如果对 $\forall \mathbf{x}^{(1)}, \mathbf{x}^{(2)} \in S, \forall \lambda \in (0, 1)$ 恒有

$$f(\lambda \mathbf{x}^{(1)} + (1 - \lambda) \mathbf{x}^{(2)}) \leq \lambda f(\mathbf{x}^{(1)}) + (1 - \lambda) f(\mathbf{x}^{(2)}) \quad (1.5)$$

则称 f 为 S 上的凸函数。如果式 (??) 恒以严格不等式成立，则称 f 为 S 上的严格凸函数。

几何意义：任意两个点连线在函数曲线的上方。

1.2.2.2.1 水平集

定义 2-8：设 $S \subset \mathbf{R}^n$ ，非空， $f: S \rightarrow \mathbf{R}, a \in \mathbf{R}$ ，则称

$$S_\alpha = \{\mathbf{x} | f(\mathbf{x}) \leq \alpha, \mathbf{x} \in S\} \quad (1.6)$$

为 f 的水平集。

水平集的概念相当于在地形图中，海拔高度不高于某一数值的区域。

注意：容易证明，当 f 为凸函数时， $\forall \alpha \in \mathbf{R}, S_\alpha$ 是凸集。但是它的逆不成立。

1.2.2.2 凸函数的性质

1. 定理 $f(x)$ 为凸集 S 上的凸函数 $\Leftrightarrow S$ 上任意有限点的凸组合的函数值不大于各点函数值的凸组合

2. 设 f_1, f_2 为凸函数, $\lambda_1, \lambda_2 > 0$, 则:

- $\lambda_1 f_1 + \lambda_2 f_2$ 是凸函数
- $f(x) = \max\{f_1(x), f_2(x)\}$ 是凸函数
- $g(x) = \min\{f_1(x), f_2(x)\}$ 不一定是凸函数

3. 若 f 在 S 上凸, 那么 f 在 S 的内点集 ($\text{int}S$) 上连续 (注: f 在 S 上不一定连续)

4. 若 f 在非空凸集 S 上凸, 则对任意方向的方向导数存在

凸函数常用判定条件:

5. 设 S 非空, 凸集, 开集, f 在 S 上可微, 则:

- f 在 S 上凸 $\Leftrightarrow \forall \bar{x} \in S$, 有 $f(x) \geq f(\bar{x}) + \nabla f^T(\bar{x})(x - \bar{x}), \forall x \in S$.
- f 在 S 上严格凸 $\Leftrightarrow \forall \bar{x} \in S$, 有 $f(x) > f(\bar{x}) + \nabla f^T(\bar{x})(x - \bar{x}), \forall x \in S, x \neq \bar{x}$.

6. 设 S 非空, 凸集, 开集, f 在 S 上可微, 则:

- f 在 S 上凸 $\Leftrightarrow \forall x^{(1)}, x^{(2)} \in S, (\nabla f(x^{(1)}) - \nabla f(x^{(2)}))^T(x^{(1)} - x^{(2)}) \geq 0$
- f 在 S 上严格凸 $\Leftrightarrow \forall x^{(1)}, x^{(2)} \in S, x^{(1)} \neq x^{(2)}, (\nabla f(x^{(1)}) - \nabla f(x^{(2)}))^T(x^{(1)} - x^{(2)}) > 0$

7. 设 S 是开集, f 在 S 上二次可微, 则:

- f 在 S 上凸 $\Leftrightarrow \forall x \in S, \nabla^2 f(x)$ 半正定。
- 如果 $\forall x \in S, \nabla^2 f(x)$ 正定, 则 f 在 S 上严格凸。

但是, 上课讲的时候, 一般是使用黑塞矩阵是否正定判断

1. 当 H 为半正定时, f 为凸函数; 若 H 是正半定的, 当且仅当 H 的每一个主子式都大于等于 0
2. 当 H 为正定时, f 为严格凸函数; 若 H 是正定矩阵, 当且仅当 H 的 n 个顺序主子式 (严格) 为正。
3. 当 H 为半负定时, f 为凹函数; 若 H 是负半定的, 当且仅当 H 的每一个奇阶的主子式小于等于 0, 每一个偶阶的主子式大于等于 0
4. 当 H 为负定时, f 为严格凹函数; 若 H 是负定矩阵, 当且仅当 H 的 N 个顺序主子式以如下方式交替出现: $|A_1| < 0, |A_2| > 0, |A_3| < 0, \dots$
5. 当 H 为不定时, f 既非凸也非凹函数。

(! 注意: 只能一个方向判断, 不能由是否凸函数来判断矩阵是否正定)

具体可看: 数学选读 01: 矩阵的主子式与顺序主子式

1.2.2.3 凸规划

定义:

- 当 (fS) 中, S 为凸集, f 是 S 上的凸函数 (求 \min 时), 称 (fS) 为凸规划。
- 对于 (fgh) , 当 f, g_i 为凸函数, h_i 为线性函数时, (fgh) 为凸规划。

定理 2-4: 设 $S \subset \mathbf{R}^n$, 非空, 凸, $f: S \rightarrow \mathbf{R}$ 是凸函数。 x^* 为问题 (fS) 的 l.opt., 则 x^* 为 g.opt.; 又如果 f 是严格凸函数, 那么 x^* 是问题 (fS) 的唯一 g.opt.。

1.2.3 多面体、极点、极方向

(看书上 p29 开始的图更好理解)

多面体: 有限个半闭空间的交为多面体

极点: $x \in S$, 不存在 S 中另外两个点 $x^{(1)}$ 和 $x^{(2)}$, 及 $\lambda \in (0, 1)$, 使 $x = \lambda x^{(1)} + (1 - \lambda)x^{(2)}$

根据定义, 闭球体的表面上每一点都是极点; 一般的闭凸锥有唯一极点, 即顶点; 平面没有极点;

极方向:

- 方向: $d \in \mathbf{R}^n, d \neq 0$ 及对于任意 $x \in S, \lambda > 0$, 总有 $x + \lambda d \in S$ (可行方向)。其中, 当 $d^{(1)} = \lambda d^{(2)} (\lambda > 0)$ 时, 称 $d^{(1)}$ 和 $d^{(2)}$ 同方向。
- 极方向: 方向 d 不能表示为两个不同方向的组合 ($d = d^{(1)} + d^{(2)}$)。

1.2.3.1 极点特征定理

设 A 行满秩, x 是 S 极点的充要条件是:

存在分解 $A = (B, N)$, 其中 B 为 m 阶非奇异矩阵, 使 $x^T = (x_B^T, x_N^T)$, 这里 $x_B = B^{-1}b \geq 0, x_N = 0$
 S 中必定存在有限多个极点 ($\leq C_n^m$)

Chapter 2

Linear Programming Problem

2.1 Graphical Method

图解法

具体可看 ppt 或：【运筹学】线性规划图解法（唯一最优解 | 无穷最优解 | 无界解 | 无可行解）

基本解：各个等式约束直线的交点，外加与坐标轴的交点

基本可行解：基本解里面在可行域范围的那些基本解，可行域的顶点

最优解：基本可行解里面使目标函数最大（最小）的基本可行解

2.2 Simplex Method

一些必要概念：（建议先了解解题步骤，再回过头来看概念）

线性规划的标准形式

$$(LP) \begin{cases} \max & \mathbf{c}^T \mathbf{x} \\ \text{s.t.} & \mathbf{Ax} = \mathbf{b} \\ & \mathbf{x} \geq \mathbf{0} \end{cases} \quad (2.1)$$

其中， \mathbf{A} 是 $m \times n$ 的矩阵 ($m < n$)

$$\mathbf{A} = \begin{pmatrix} a_{11} & \cdots & a_{1m} & a_{1(m+1)} & \cdots & a_{1n} \\ \vdots & & \vdots & \vdots & & \vdots \\ a_{m1} & \cdots & a_{mm} & a_{m(m+1)} & \cdots & a_{mn} \end{pmatrix}$$

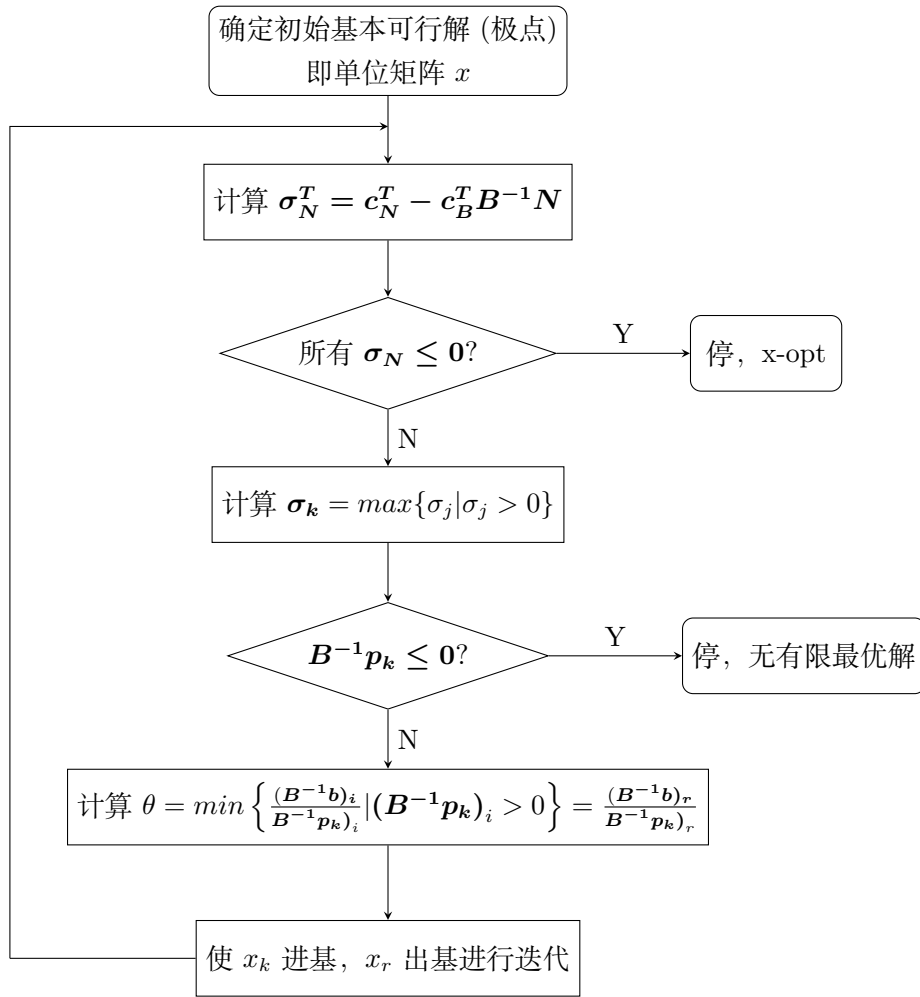
可行解：在公式 (??) 中， $\mathbf{x} = (x_1, \dots, x_n)^T$ 即为可行解，可以理解为多面体的极点（顶点？）

基本可行解：可以理解为满足非负约束条件的可行解？（非负约束条件大概就是公式 (??) 中 $\mathbf{x} \geq \mathbf{0}$ ）

基： \mathbf{B} 是线性规划问题的一个基

$$\mathbf{B} = \begin{pmatrix} a_{11} & \cdots & a_{1m} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mm} \end{pmatrix}$$

\mathbf{B} 中的每个列向量 $\mathbf{p}_j = (a_{1j}, a_{2j}, \dots, a_{mj})^T$ 为基向量，基向量中的 a_{mj} 们即为基变量。一般的，我们讲基变量为 m 个线性无关的变量。（一般是标准化后的松弛变量所对应的列们的系数，也是单位矩阵）



需要注意的是, σ 在表中的计算没有那么复杂, 可以先略过。

2.2.1 单纯形法的表格计算

考虑规范形式的线性规划问题: $b_i > 0, i = 1, \dots, m$

$$\begin{aligned}
 \max \quad & z = c_1 x_1 + c_2 x_2 + \dots + c_n x_n \\
 \text{s.t.} \quad & \begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n & \leq b_1 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n & \leq b_2 \\ \vdots & \\ a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n & \leq b_m \\ x_1, x_2, \dots, x_n & \geq 0 \end{cases}
 \end{aligned}$$

加入松弛变量，化为标准形：

$$\left\{ \begin{array}{ll} \max & z = c_1x_1 + c_2x_2 + \cdots + c_nx_n \\ \text{s.t.} & a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n + x_{n+1} = b_1 \\ & a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n + x_{n+2} = b_2 \\ & \vdots \\ & a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n + x_{n+m} = b_m \\ & x_1, x_2, \cdots, x_n, x_{n+1}, \cdots, x_{n+m} \geq 0 \end{array} \right. \quad (2.2)$$

STEPS:

1. 根据公式 (??) 构造初始单纯形表：

c_B	x_B	b	c_1	c_2	\cdots	c_n	c_{n+1}	c_{n+2}	\cdots	c_{n+m}	θ
			x_1	x_2	\cdots	x_n	x_{n+1}	x_{n+2}	\cdots	x_{n+m}	
c_{n+1}	x_{n+1}	b_1	a_{11}	a_{12}	\cdots	a_{1n}	1	0	\cdots	0	θ_1
c_{n+2}	x_{n+2}	b_2	a_{21}	a_{22}	\cdots	a_{2n}	0	1	\cdots	0	θ_2
\vdots	\vdots	\vdots	\vdots	\vdots		\vdots	\vdots	\vdots		\vdots	\vdots
c_{n+m}	x_{n+m}	b_m	a_{m1}	a_{m2}	\cdots	a_{mn}	0	0	\cdots	1	θ_m
$-z$		$-z'$	σ_1	σ_2	\cdots	σ_n	0	0	\cdots	0	

表 2.1: 单纯形表

表 (??) 中；

- 列 c_B 填入目标函数中基变量 x 的系数
- 列 x_B 填入基变量
- 列 b 填入约束方程右端的常数
- 中间 4-11 列填入约束方程中 x 的系数，其中从 x_{n+1} 开始的列组成单位矩阵

2. 求出 $-z' = -\sum_{i=1}^m c_{n+i}b_i$ (初始状态下一般为 0)

3. 求出**检验数** $\sigma_j = c_j - \sum_{i=1}^m c_{n+i}a_{ij}$ ，可以通俗理解为 $\sigma_1 =$ 第一行中的 c_1 减去 (c_B 的每一项与 c_1 列对应行的 a_{11} 相乘的求和)。

需要注意的是，这里的检验数不需要考虑基（即单位矩阵）对应的列，否则会影响下一步。

4. 判断是否所有检验数 $\sigma_j \leq 0$ ，如果全部小于等于 0，则当前的基本可行解是最优解；如果有一检验数大于 0，那么进行下一步的计算。

5. 求入基变量 x_k ：

- 先求出大于 0 的检验数中最大的**检验数** σ_k
- 得到的下标 k ， σ_k 所在的列就是主元列

- 那么所对应的 x_k 就是入基变量

6. 求出基变量 x_r :

- 找出主元列 (x_k 列) 对应元素 $a_{ik} > 0$ 的
- 使每个大于 0 的 a_{ik} 被对应行中的 b_i 除, 得到 $\theta_i = \frac{b_i}{a_{ik}}$
(若 $a_{ik} \leq 0$, 则 $\theta_i = \infty$)
- 找出 $\min\{\theta_i\} = \theta_r$
- 此时 θ_r 所在的行 r 即为主元行, x_r 为出基变量

7. 求出入基变量 x_k 和出基变量 x_r 后, 就可以构建下一张表, 这张表中:

- x_B 上的出基变量被入基变量所取代, 同时需要更改列 c_B 中与之相对应的行的元素
- 在表右侧中间部分, 使用高斯消元法将 x_k 对应的 a 与其他基变量对应的 a 组成一个单位矩阵, 同时列 b 也跟着改变
- 表 2 基本构建完成, 重复第二步, 直至出现流程表中 stop 的情况

2.2.2 一般线性规划问题的处理

在某些情况下, 如基本初始可行解不明显, 即很难在标准形的问题下找到单位矩阵时, 可以考虑使用大 M 法与二阶段法

2.2.2.1 大 M 法

STEPS:

1. 将线性规划问题转化为标准型
2. 观察变量, 若初始基本可行解明显, 直接进行单纯形法; 否则引入人工变量 $x_{n+i} \geq 0 (i = 1, \dots, m)$ 及充分大正数 M , 改写原目标函数, 进行单纯形法
3. 若得到的最优解满足:

$$x_{n+i} = 0 \quad (i = 1, \dots, m)$$

则是原问题的最优解; 否则, 原问题无可行解

例: 使用大 M 法求解下面的问题

$$\begin{aligned} \max \quad & z = 5x_1 + 2x_2 + 3x_3 - x_4 \\ \text{s.t.} \quad & \begin{cases} x_1 + 2x_2 + 3x_3 & = 15 \\ 2x_1 + x_2 + 5x_3 & = 20 \\ x_1 + 2x_2 + 4x_3 + x_4 & = 26 \\ x_1, x_2, x_3, x_4 & \geq 0 \end{cases} \end{aligned}$$

标准化并引入人工变量：

$$\begin{aligned} \max \quad & z = 5x_1 + 2x_2 + 3x_3 - x_4 - Mx_5 - Mx_6 \\ \text{s.t.} \quad & \begin{cases} x_1 + 2x_2 + 3x_3 + x_5 = 15 \\ 2x_1 + x_2 + 5x_3 + x_6 = 20 \\ x_1 + 2x_2 + 4x_3 + x_4 = 26 \\ x_1, x_2, x_3, x_4, x_5, x_6 \geq 0 \end{cases} \end{aligned}$$

最后使用单纯形法计算

c_B	x_B	b	5	2	3	-1	$-M$	$-M$	θ
			x_1	x_2	x_3	x_4	x_5	x_6	
$-M$	x_5	15	1	2	3	0	1	0	5
$-M$	x_6	20	2	1	[5]	0	0	1	4
-1	x_4	26	1	2	4	1	0	0	6.5
$-z$		$35M + 26$	$3M + 6$	$3M + 4$	$8M + 7$	0	0	0	
$-M$	x_5	3	-1/5	[7/5]	0	0	1	-3/5	15/7
3	x_3	4	2/5	1/5	1	0	0	1/5	20
-1	x_4	10	-3/5	6/5	0	1	0	-4/5	25/3
$-z$		$3M - 2$	$-M/5 + 16/5$	$7/5M + 13/5$	0	0	0	$-8/5M - 7/5$	
2	x_2	15/7	-1/7	1	0	0	5/7	-3/7	25/3
3	x_3	25/7	[3/7]	0	1	0	-1/7	2/7	
-1	x_4	52/7	-3/7	0	0	1	-6/7	-2/7	
$-z$		-53/7	25/7	0	0	0	$-M - 13/7$	$-M - 2/7$	
2	x_2	10/3	0	1	1/3	0	2/3	-1/3	
5	x_1	25/3	1	0	7/3	0	-1/3	2/3	
-1	x_4	11	0	0	1	1	-1	-0	
$-z$		-112/3	0	0	-25/3	0	$-M - 2/3$	$-M + 8/3$	

表 2.2: 大 M 法例题

得到基本可行解： $(25/3, 10/3, 0, 11)^T$ 为最优解

得到最优值 $z = 112/3$

2.2.2.2 二阶段法

STEPS:

1. 将线性规划问题转化为标准型
2. 观察变量，若初始基本可行解明显，直接进行单纯形法；否则引入人工变量 $x_{n+i} \geq 0 (i = 1, \dots, m)$ 构造辅助问题 (LP - 1)
3. 第一阶段，求解辅助问题 (LP - 1)，若得到的最优解满足 $x_{n+i} = 0 (i = 1, \dots, m)$ ，则是原问题的基本可行解；否则，原问题无可行解。

4. 第二阶段, 得到原问题的基本可行解后, 直接删除人工变量, 求解原问题

例: 使用二阶段法求解下面的问题

$$\begin{aligned} \max \quad & z = 5x_1 + 2x_2 + 3x_3 - x_4 \\ \text{s.t.} \quad & \begin{cases} x_1 + 2x_2 + 3x_3 & = 15 \\ 2x_1 + x_2 + 5x_3 & = 20 \\ x_1 + 2x_2 + 4x_3 + x_4 & = 26 \\ x_1, x_2, x_3, x_4 \geq 0 \end{cases} \end{aligned}$$

标准化、引入人工变量并构造第一阶段问题 (LP - 1):

$$\begin{aligned} \max \quad & z' = -x_5 - x_6 \\ \text{s.t.} \quad & \begin{cases} x_1 + 2x_2 + 3x_3 + x_5 & = 15 \\ 2x_1 + x_2 + 5x_3 + x_6 & = 20 \\ x_1 + 2x_2 + 4x_3 + x_4 & = 26 \\ x_1, x_2, x_3, x_4, x_5, x_6 \geq 0 \end{cases} \end{aligned}$$

建立第一阶段的单纯形表:

c_B	x_B	b	0	0	0	0	-1	-1	θ
			x_1	x_2	x_3	x_4	x_5	x_6	
-1	x_5	15	1	2	3	0	1	0	5
-1	x_6	20	2	1	[5]	0	0	1	4
0	x_4	26	1	2	4	1	0	0	6.5
$-z$		35	3	3	8	0	0	0	
-1	x_5	3	-1/5	[7/5]	0	0	1	-3/5	15/7
0	x_3	4	2/5	1/5	1	0	0	1/5	20
0	x_4	10	-3/5	6/5	0	1	0	-4/5	25/3
$-z$		3	-1/5	7/5	0	0	0	-8/5	
2	x_2	15/7	-1/7	1	0	0	5/7	-3/7	25/3
3	x_3	25/7	[3/7]	0	1	0	-1/7	2/7	
-1	x_4	52/7	-3/7	0	0	1	-6/7	-2/7	
$-z$		0	0	0	0	0	-1	-1	

表 2.3: 二阶段法例题 1

得到原问题的基本可行解 $(0, 15/7, 25/7, 52/7)^T$

第二阶段删除人工变量, 并把基本可行解填入表中

得到基本可行解: $(25/3, 10/3, 0, 11)^T$ 为最优解

得到最优值 $z = 112/3$

(表见下页)

c_B	x_B	b	0	0	0	0	θ
			x_1	x_2	x_3	x_4	
2	x_2	15/7	-1/7	1	0	0	25/3
3	x_3	25/7	[3/7]	0	1	0	
-1	x_4	52/7	-3/7	0	0	1	
$-z$		-53/7	25/7	0	0	0	
2	x_2	10/3	0	1	1/3	0	
5	x_1	25/3	1	0	7/3	0	
-1	x_4	11	0	0	1	1	
$-z$		-112/3	0	0	-25/3	0	

表 2.4: 二阶段法例题 2

2.2.3 线性规划的对偶问题

给定一个优化问题，我们去理解它的时候，或者设计算法的时候，可以研究它的对偶。

有时原问题不好解，但它的对偶相对容易。这个时候，可以从对偶问题出发，进而寻求原问题的解。

2.2.3.1 对偶问题的形式

1. 对称形式的对偶问题

$$(P) \begin{cases} MAX & z = \mathbf{c}^T \mathbf{x} \\ s.t. & A\mathbf{x} \leq \mathbf{b} \\ & \mathbf{x} \geq 0 \end{cases} \quad (D) \begin{cases} MIN & f = \mathbf{b}^T \mathbf{y} \\ s.t. & A^T \mathbf{y} \geq \mathbf{c} \\ & \mathbf{y} \geq 0 \end{cases}$$

一对对称形式的对偶规划之间具有下面的对应关系

- “Max \leq ” 和 “Min \geq ” 相对应
- 从约束系数矩阵看：一个模型中为 A ，则另一个模型中为 A^T ；一个模型是 m 个约束、 n 个变量，则它的对偶模型为 n 个约束、 m 个变量
- 从数据 b 、 c 的位置看：在两个规划模型中， b 和 c 的位置对换
- 两个规划模型中的变量皆非负

2. 非对称形式的对偶问题

(下式并不囊括所有情况)

$$(P) \begin{cases} MAX & z = \mathbf{c}^T \mathbf{x} \\ s.t. & A\mathbf{x} = \mathbf{b} \\ & \mathbf{x} \geq 0 \end{cases} \quad (D) \begin{cases} MIN & f = \mathbf{b}^T \mathbf{y} \\ s.t. & A^T \mathbf{y} \geq \mathbf{c} \end{cases}$$

一般称不具有对称形式的一对线性规划为非对称形式的对偶规划。对于非对称形式的规划，可以按照下面的对应关系直接给出其对偶规划。

- 将模型统一为 “ $Max \leq$ ” 或 “ $Min \geq$ ” 的形式
- 若原规划的某个约束条件为等式约束，则在对偶规划中与此约束对应的那个变量取值没有非负限制
- 若原规划的某个变量的值没有非负限制，则在对偶问题中与此变量对应的那个约束为等式

原问题与对偶问题的对应关系

原问题（对偶问题）		对偶问题（原问题）	
min		max	
变量	n 个变量	约束	n 个约束
	变量 ≥ 0		约束 \leq
	变量 ≤ 0		约束 \geq
	无正负限制		约束 $=$
约束	m 个约束	变量	m 个变量
	约束 \leq		变量 ≤ 0
	约束 \geq		变量 ≥ 0
	约束 $=$		无正负限制
约束条件右端项 目标函数中的变量系数		目标函数中的变量系数 约束条件右端项	

表 2.5: 原问题与对偶问题的对应关系

2.2.3.2 对偶定理

设有一对互为对偶的线性规划

$$(P) \begin{cases} MAX & z = \mathbf{c}^T \mathbf{x} \\ s.t. & A\mathbf{x} \leq \mathbf{b} \\ & \mathbf{x} \geq 0 \end{cases} \quad (D) \begin{cases} MIN & f = \mathbf{b}^T \mathbf{y} \\ s.t. & A^T \mathbf{y} \geq \mathbf{c} \\ & \mathbf{y} \geq 0 \end{cases}$$

定理 3-3: 若 \mathbf{x} 和 \mathbf{y} 分别为原规划 (P) 和 (D) 对偶规划，则

$$\mathbf{c}^T \mathbf{x} \leq \mathbf{b}^T \mathbf{y}$$

推论 3-1: 设 \mathbf{x} 和 \mathbf{y} 分别为原规划 (P) 和 (D) 的可行解，当 $\mathbf{c}^T \mathbf{x} = \mathbf{b}^T \mathbf{y}$ 时， \mathbf{x}, \mathbf{y} 分别是两个问题的最优解

推论 3-2: 若规划 (P) 有可行解，则规划 (P) 有最优解的充分必要条件是规划 (D) 有可行解

推论 3-3: 若规划 (D) 有可行解，则规划 (D) 有最优解的充分必要条件是规划 (P) 有可行解

定理 3-4: 若原规划 (P) 有最优解，则对偶规划 (D) 也有最优解，反之亦然，且两者的目标函数值相等。

2.2.3.3 对偶单纯形法

对偶单纯形法是求解原规划的一种方法。

原理：

作为原规划的一个解，会有两个性质等待满足：可行性和最优性。而原问题的可行性和最优性恰好对应于对偶问题的最优性和可行性。

单纯形法的思路是，先满足可行性，再逐渐逼近最优性；而对偶单纯形法的思路是，先找到最优性，再逐渐逼近可行性。

也就是说，先找到对偶问题的可行解，再找到原问题的可行解（即对偶问题的最优解）。

最优性：看检验数 σ_j 可行性：看右端项 b_i

从原规划的一个基本解出发，此基本解不一定可行，但它对应着一个对偶可行解；就是说可以从一个对偶可行解出发，然后检验原规划的基本解是否可行，即是否有负的分量。如果有负的分量，则进行迭代，求另一个基本解，此基本解对应着另一个对偶可行解（检验数非正）；而得到的基本解的分量皆非负，则该基本解为最优解。

也就是说，对偶单纯形法在迭代过程中始终保持对偶解的可行性（检验数非正），使得原规划的基本解由不可行变为可行，当同时得到对偶规划与原规划的可行解时，得到原规划的最优解。

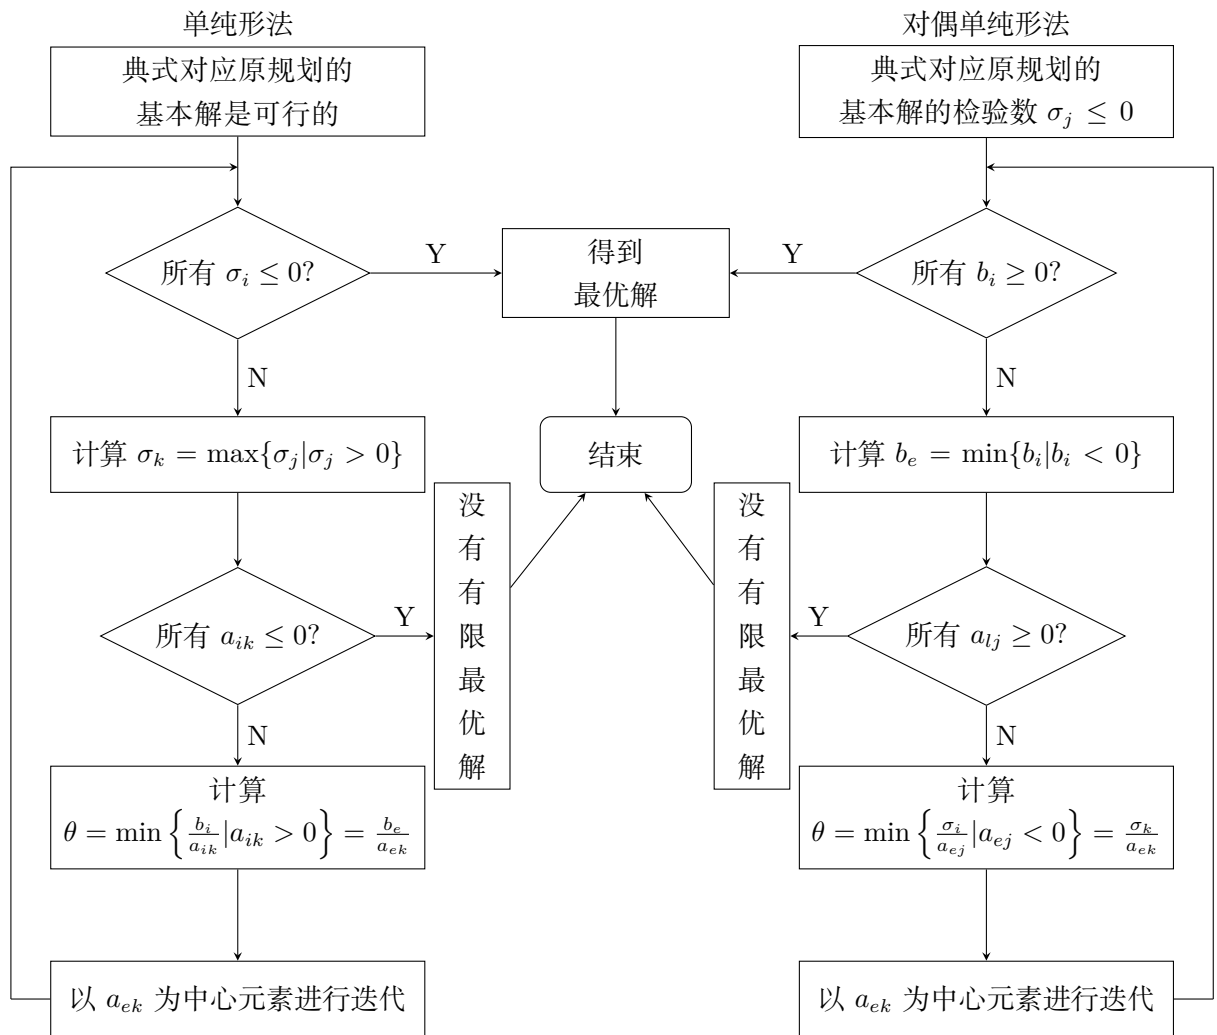
STEPS:

1. 根据线性规划典式形式，建立初始单纯形表（就是还按照单纯形法填初始单纯形表）。此表对应原规划的一个基本解。表要求：检验数数行各元素一定非正，原规划的基本解可以有小于零的分量。
2. 若基本解的所有分量皆非负，则得到原规划的最优解，停止计算；若基本解中有小于零的分量 b_i ，并且 b_i 所在行各系数 $a_{ij} \geq 0$ ，则原规划无可行解，停止计算；若 $b_i < 0$ ，并且存在 $a_{ir} < 0$ ，则确定 x_r 为出基变量，并计算

$$\theta = \min \left\{ \frac{\sigma_j}{a_{rj}} \mid a_{rj} < 0 \right\} = \frac{\sigma_k}{a_{rk}}$$

确定 x_k 为进基向量。若有多个 $b_i < 0$ ，则选择最小的进行分析计算。

3. 以 b_{rk} 为中心元素，按照与单纯形法类似的方法，在表中进行迭代计算，返回第 2 步。



2.2.4 灵敏度分析

前提：在求灵敏度分析和影子价格中，常常会遇到要使用对偶问题的最优解（或最优基 B ）求解问题，这里解释一下怎么使用最优单纯形表求得。

1. 首先利用单纯形法得到最优单纯形表
2. 得到 b 列的 n 个数值，最优单纯形表从后往前数 n 列（就是松弛变量对应的列），有矩阵：

$$\begin{pmatrix} a_{1(m-n)} & a_{1(m-n+1)} & \cdots & a_{1m} \\ a_{2(m-n)} & a_{2(m-n+1)} & \cdots & a_{2m} \\ \vdots & \vdots & \vdots & \vdots \\ a_{n(m-n)} & a_{n(m-n+1)} & \cdots & a_{nm} \\ \hline \sigma_{m-n} & \sigma_{m-n} & \cdots & \sigma_{m-n} \end{pmatrix}$$

其中：

- 最后一行的检验数 $\sigma^T = -c_B^T B^{-1}$ ，各检验数取相反数（即 $c_B^T B^{-1}$ ）即为对偶问题的最优解。
- 除最后一行外（即线上方的）矩阵即为 B^{-1}

2.2.4.1 影子价格

影子价格是一个向量，它的分量表示最优目标值随相应资源数量变化的变化率。

若 x^*, y^* 分别为 (LP) 和 (DP) 的最优解，那么有

$$c^T x^* = b^T y^*$$

根据 $f = b^T y^* = b_1 y_1^*, b_2 y_2^*, \dots, b_m y_m^*$ 可知

$$\frac{\partial f}{\partial b_i} = y_i^*$$

y_i^* 表示 b_i 变化一个单位对目标 f 产生的影响，称 y_i^* 为 b_i 的影子价格

需要指出，影子价格不是固定不变的，当约束条件、产品利润等发生变化时，有可能使影子价格发生变化。另外，影子价格的经济含义，是指资源在一定范围内增加时的情况，当某种资源的增加超过了这个“一定的范围”时，总利润的增加量则不是按照影子价格给出的数值线性地增加。

如何求解影子价格：

1. 求出对偶问题的最优解（可以利用单纯形表，在求出最优解的情况下，将松弛变量对应的各检验数取负 $-\sigma_i$ 就能得到对偶问题的最优解）
2. 对偶问题最优解中的数字依次对应的就是原问题的各资源影子价格

经济意义： 每增加一单位的某资源，最终收益增加多少单位

判断资源是否有剩余： $\begin{cases} y_i^* = 0 & \text{有剩余} \\ y_i^* > 0 & \text{无剩余} \end{cases}$

2.2.4.2 目标函数系数 c 变化*

若只有一个系数 c_j 变化，其他系数不变。 c_j 的变化只影响检验数 σ_j ，而不影响解的非负性。

$$\sigma_j = c_j - c_B^T B^{-1} p_j, j = 1, 2, \dots, n$$

1. c_k 是非基变量的系数

非基系数变化只影响与 c_k 有关的一个检验数 σ_k 的变化，对其他无影响，故只需要考虑 σ_k 。

设 $c_k \rightarrow \bar{c}_k = c_k + \Delta c_k$ ，有 σ_k 的变化：

$$\bar{\sigma}_k = c_k + \Delta c_k - c_B^T B^{-1} p_j = \sigma_k + \Delta c_k$$

为了保持最优解不变， σ_k 必须满足 $\bar{\sigma}_k = \sigma_k + \Delta c_k \leq 0$ 。也就是说：

$$\Delta c_k \leq -\sigma_k, \bar{c}_k = c_k + \Delta c_k \leq c_k - \sigma_k \quad (2.3)$$

$c_k - \sigma_k$ 是 c_k 变化的上限，若 c_k 不超出上限，最优解不变；否则，将最优单纯形表中的检验数 σ_k 用 $\bar{\sigma}_k$ 取代，取 x_k 为进基变量，继续单纯形的表格计算。

2. c_l 是基变量的系数

设 $c_l \rightarrow c_l + \Delta c_l$ ，引入 $\Delta c = (0, \dots, 0, \Delta c_l, 0, \dots, 0)$ ，有

$$\begin{aligned} \sigma_j &\rightarrow \bar{\sigma}_j = c_j - [c_B^T + (\Delta c)^T] B^{-1} p_j, j \neq l \\ &= \sigma_j - \Delta c_l a'_{lj} \end{aligned}$$

(注意：上式中 a 的 l 与左边基变量的下标对应) 为保证最优解不变, Δc_l 要满足

$$\max \left\{ \frac{\sigma_j}{a'_{ij}} | a'_{ij} > 0 \right\} \leq \Delta c_l \leq \min \left\{ \frac{\sigma_j}{a'_{ij}} | a'_{ij} < 0 \right\}$$

若 Δc_l 超出此范围, 应求出新的检验数 $\bar{\sigma}_j$, 选择其中大于零的检验数对应的变量 x_j 为进基变量, 继续迭代。

2.2.4.3 右端常数 b 变化 *

b_r 的变化影响解的可行性, 但不影响检验数的符号变化。由 $x_B = B^{-1}b$ 可知 b_r 的变化必会引起最优解数值变化。

最优解的变化分为以下两类:

1. 保持 $B^{-1}b \geq 0$, 即最优基 B 不变 (影子价格不变, 也就是对偶问题的最优解不变)
只需要将变化后的 b_r 带入 $B^{-1}b$ 的表达式重新计算即可
2. $B^{-1}b$ 出现负分量, 这使最优基 B 变化
需要通过迭代求解新的最优基和最优解

综合一下, 可以利用下面的步骤计算:

设 $b_r \rightarrow \bar{b}_r = b_r + \Delta b_r$, Δb_r , 此时有

$$x_B \rightarrow \bar{x}_B = B^{-1} \begin{pmatrix} b_1 \\ \vdots \\ b_r + \Delta b_r \\ \vdots \\ b_m \end{pmatrix} = B^{-1}b + B^{-1} \begin{pmatrix} 0 \\ \vdots \\ \Delta b_r \\ \vdots \\ 0 \end{pmatrix} = x_B + \Delta b_r \begin{pmatrix} \beta_{1r} \\ \vdots \\ \beta_{mr} \end{pmatrix} = \begin{pmatrix} b'_1 \\ \vdots \\ b'_m \end{pmatrix} + \Delta b_r \begin{pmatrix} \beta_{1r} \\ \vdots \\ \beta_{mr} \end{pmatrix} \geq \begin{pmatrix} 0 \\ \vdots \\ 0 \end{pmatrix}$$

(上式只需要随便算其中的一个, 然后看是否大于等于 0 就行, 不需要特别算下面的 Δb_r)

其中, 为 $x_B = B^{-1}b$ 原最优解, b'_i 为 $x_B = B^{-1}b$ 的第 i 个分量, β_{ir} 为 B^{-1} 的第 i 行第 r 列元素要满足

$$\max \left\{ \frac{-b'_i}{\beta_{ir}} | \beta_{ir} > 0 \right\} \leq \Delta b_r \leq \min \left\{ \frac{-b'_i}{\beta_{ir}} | \beta_{ir} < 0 \right\}$$

当 Δb_r 超过此范围时, 将使最优解中某个分量小于零, 使最优基发生变化。此时可用对偶单纯形法继续迭代新的最优解。

就是说, 如果没超范围, 直接把 \bar{x}_B 当最优解得出就行; 如果超范围的话, 就把 \bar{x}_B 放到最优单纯形表的 b 列, 然后求对偶单纯形。

2.2.4.4 约束条件系数 a 变化

假设只有一个 a_{ij} 变化, 其他数据不变, 且只讨论 a_{ij} 为非基变量 x_j 的系数的情况。那么此时 a_{ij} 的变化只影响一个检验数 σ_j 。

设 $a_{ij} \rightarrow a_{ij} + \Delta a_{ij}$, 由检验数的另一种表示形式

$$\sigma_j \rightarrow \bar{\sigma}_j = c_j - \mathbf{y}^T \begin{pmatrix} a_{1j} \\ \vdots \\ a_{ij} + \Delta a_{ij} \\ \vdots \\ a_{mj} \end{pmatrix} = c_j - \mathbf{y}^T \mathbf{p}_j - \mathbf{y}^T \begin{pmatrix} 0 \\ \vdots \\ \Delta a_{ij} \\ \vdots \\ 0 \end{pmatrix} = \sigma_j - y_i^* \Delta a_{ij}$$

其中, \mathbf{y} 为对偶最优解, y_i^* 为 \mathbf{y} 的第 i 个变量

为使最优解不变, 要使 $\sigma_j \leq 0$, 即

$$\begin{aligned} \sigma_j &\leq y_i^* \Delta a_{ij} \\ \Delta a_{ij} &\geq \frac{\sigma_j}{y_i^*}, y_i^* > 0 \\ \Delta a_{ij} &\leq \frac{\sigma_j}{y_i^*}, y_i^* < 0 \end{aligned}$$

2.2.4.5 新增变量 x 分析

增加变量 x_{n+1} , 则有相应的约束条件 \mathbf{p}_{n+1} , 目标函数系数 c_{n+1} , 那么, 计算出

$$\sigma_{n+1} = c_{n+1} - \mathbf{c}_B^T \mathbf{B}^{-1} \mathbf{p}_{n+1}$$

填入最优单纯形表, 若 $\sigma_{n+1} \leq 0$, 则最优解不变; 否则, 进一步用单纯形法求解

2.2.4.6 新增约束条件

增加一个约束之后, 应把最优解代入新的约束, 若满足, 则最优解不变; 否则, 填入最优单纯形表作为新的一行, 引入一个新的非负变量 (原约束若是小于等于形式, 可引入非负松弛变量; 否则, 引入非负人工变量), 并通过矩阵行变换把对应基变量的元素变为 0, 进一步用单纯形法或对偶单纯形法求解。

Chapter 3

最优化搜索算法的结构和一维搜索

从此章开始就是求非线性规划问题，与线性规划问题可以在有限步数内得到解不同，非线性规划问题不一定可以在有限的迭代步数内收敛。

3.1 常用的搜索算法结构

3.1.1 收敛性概念

在规划问题的求解过程中，由于迭代算法是以产生一系列迭代点为目的的，因此算法的收敛性表现在产生的点列 $\{\mathbf{x}^{(k)}\}$ 上。

1. 理想的收敛性概念：设 \mathbf{x}^* 为问题 (f, S) 的全局最优解。当 $\mathbf{x}^* \in \{\mathbf{x}^{(k)}\}$ 或 $\mathbf{x}^{(k)} \neq \mathbf{x}^*$ 对于所有 k 成立，并且满足 $\lim_{k \rightarrow \infty} \mathbf{x}^{(k)} = \mathbf{x}^*$ 时，称算法收敛到最优解 \mathbf{x}^* 。
2. 然而，由于实际问题较为复杂，很难达到理想状态，因此需要引入一些实用的收敛性概念：

首先定义解集 Ω ，是具有某种可接受性质的点集，通常取下面的几种集合：

- (a) $\Omega = \{\mathbf{x}^* | \mathbf{x}^* \text{ is } g.\text{opt}\}$
- (b) $\Omega = \{\mathbf{x}^* | \mathbf{x}^* \text{ is } l.\text{opt}\}$
- (c) $\Omega = \{\mathbf{x}^* | \mathbf{x}^* \text{ 满足某种最优条件, 或者说 } \nabla f(\mathbf{x}^*) = 0\}$
- (d) $\Omega = \{\mathbf{x}^* | \mathbf{x}^* \in S, f(\mathbf{x}^*) \leq B\}$ ，其中 B 为可接受的目标函数值的一个上界

设算法产生的点列为 $\mathbf{x}^{(k)}$ ，满足下列任一情况时，称算法收敛：

- (a) $\{\mathbf{x}^{(k)}\} \cap \Omega \neq \emptyset$
- (b) $\{\mathbf{x}^{(k)}\}$ 的任意收敛子列的极限点属于 Ω

求解问题时，需要考虑初始点的影响，因此引入下面的概念：

1. 全局收敛性：若算法对任意的初始点 $\mathbf{x}^{(1)}$ 都收敛，则称算法全局收敛。
2. 局部收敛性：若算法只有限制初始点 $\mathbf{x}^{(1)}$ 到解集 Ω 附近（当 Ω 为非连通时，指在 Ω 的某个连通子集附近）时，才有收敛性，则称算法局部收敛。

3.1.2 收敛准则 (停机条件)

1. $\|\mathbf{x}^{(k+m)} - \mathbf{x}^{(k)}\| < \varepsilon$ (最常用的是 $m = 1$)
2. $\frac{\|\mathbf{x}^{(k+1)} - \mathbf{x}^{(k)}\|}{\|\mathbf{x}^{(k)}\|} < \varepsilon$
3. $|f(\mathbf{x}^{(k+1)}) - f(\mathbf{x}^{(k)})| < \varepsilon$

3.1.3 收敛速度

设 $\{\mathbf{x}^{(k)}\}$ 为算法产生的点列, 收敛于解 \mathbf{x}^* , 且 $\mathbf{x}^{(k)} \neq \mathbf{x}^*$, 有 $\forall k$

1. 线性收敛: $\exists \alpha \in (0, 1) \frac{\|\mathbf{x}^{(k+1)} - \mathbf{x}^*\|}{\|\mathbf{x}^{(k)} - \mathbf{x}^*\|} \leq \alpha, k$ 充分大时 $\mathbf{x}^{(k)}$ 收敛于 \mathbf{x}^*
表示每迭代一次, 比上一次更接近 \mathbf{x}^* ; 收敛的阶数 $p_0 = 1$
2. 超线性收敛: $\lim_{k \rightarrow \infty} \frac{\|\mathbf{x}^{(k+1)} - \mathbf{x}^*\|}{\|\mathbf{x}^{(k)} - \mathbf{x}^*\|} = 0$
迭代速度比线性收敛更快, 收敛的阶数 $p_0 \geq 1$
3. 二阶收敛: $\exists \alpha > 0$, 使得 k 充分大时, 有 $\frac{\|\mathbf{x}^{(k+1)} - \mathbf{x}^*\|}{\|\mathbf{x}^{(k)} - \mathbf{x}^*\|^2} \leq \alpha$
收敛的阶数 $p_0 = 2$, 说明二阶收敛是超线性收敛的一个特例

3.1.4 下降算法模型

